

Documentação Técnica do Pipeline de Inserção de Dados

1. Visão Geral e Objetivo

Este projeto implementa o processo de Extração, Transformação e Carga (ETL) necessário para preparar e inserir novos dados no ambiente de destino (`d_cnpj`).

O pipeline foi desenvolvido com ênfase máxima em modularidade e documentação, conforme solicitado, visando facilidade de manutenção e validação por Levy.

2. Arquitetura Modular (Para Levy!)

O código está segregado em dois módulos principais, garantindo a separação clara de responsabilidades:

Arquivo	Responsabilidade	Descrição
<code>main.py</code>	Orquestrador / Ponto de Entrada	Define os parâmetros de ambiente (caminhos, destino) e executa a pipeline . É o script que deve ser agendado.
<code>data_processor.py</code>	Lógica de ETL (Core)	Contém a classe <code>ETLProcessor</code> com os métodos isolados: <code>extract_data()</code> , <code>transform_data()</code> , e <code>load_data()</code> .

Vantagem: Se houver necessidade de mudar a regra de transformação, basta alterar apenas o método `transform_data` em `data_processor.py`, sem tocar no orquestrador.

3. Fluxo do Processo (`main.py`)

- Início:** O script `main.py` é executado.
- Inicialização:** Instancia a classe `ETLProcessor` com os caminhos de origem e destino.
- `run_pipeline()`:** O método é chamado e sequênci as etapas:
 - Extract:** Lê o CSV de origem.
 - Transform:** Aplica regras de limpeza e padronização (Ex: renomeia colunas, trata nulos).
 - Load:** Simula a inserção dos dados limpos no `PROD_DW_VENDAS`.

4. **Logging:** Todas as etapas, advertências (**WARNING**) e erros (**ERROR**) são registrados via módulo **logging**.

4. Detalhes da Transformação (Importante para Validação)

As seguintes regras de negócio e limpeza foram implementadas no método **transform_data()**:

Regra de Transformação	Ação Executada
Padronização de Colunas	Todos os nomes de colunas são convertidos para snake_case (minúsculas com _).
Tratamento de Nulos (Nulls)	Valores None ou NaN na coluna 'Status' (e outras textuais) são preenchidos com a string 'N/A'.
Cálculos/Features	Criação da coluna preco_total (se necessário), ou outra feature de validação. <i>(Implementação básica para demonstração; expandir conforme a necessidade real).</i>

5. Próximos Passos

A carga final (o **L** do ETL) está simulada no **load_data()**

Para colocar em produção, é preciso substituir a simulação de carga:

data_processor.py (trecho do método load_data)

--- SIMULAÇÃO DA INSERÇÃO REAL ---

Esta seção deve ser substituída pelo código de conexão real.

logging.info(f"SUCESSO: Simulação de inserção de {len(df)} registros...")

-----

Exemplo de código real (Ajustar conforme o SGBD)

engine = create_engine('postgresql://user:pass@host/db')

df.to_sql('tabela_destino', engine, if_exists='append', index=False)

6. Como Executar

1. `pip install pandas`

Execução:

2. `python main.py`
3. **Monitoramento:** Acompanhe o console para verificar o log de **INFO** e confirmar o status de sucesso ou falha.